UNIVERSITÄT LEIPZIG

Digital Text Forensics Search

Information Retrieval
WS 2017/2018

Betreurer: Martin Potthast
martin.potthast@uni-leipzig.de

Autor: David Drost
dd42cequ@studserv.uni-leipzig.de
Matrikelnummer:

Autor: Edward Kupfer
ek96foje@studserv.uni-leipzig.de
Matrikelnummer:

Autor: Hendrik Sawade
hs34byhe@studserv.uni-leipzig.de
Matrikelnummer: 3745956

Autor: Tobias Wenzel
tw54byka@studserv.uni-leipzig.de
Matrikelnummer: 3733301

Abgabedatum: Leipzig, den 3. März 2018

Inhaltsverzeichnis

1 Einleitung

Hier schreibt man dann was. Und so . Offenbar sieht das nicht so schön aus.

kommentiere ihr Sachen.

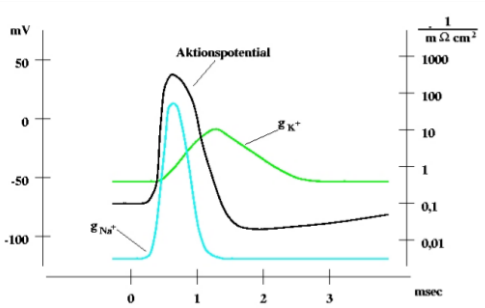

(a) Pyramidenzelle

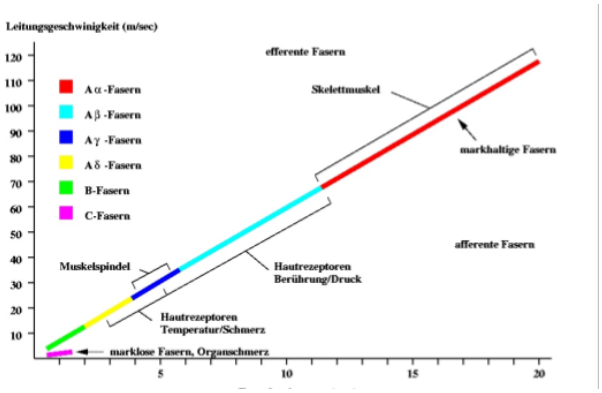

(b) Neocortex

Abbildung 1.1: Links: AP. Rechts: Leitungsgeschwindikeit von verschiedenen Fasern.

2 Vorverarbeitung

3 Indexierung

4 Backend

4.1 Auswahl eines Backend-Frameworks

Zuerst wurde für die Programmierung einer Webanwendung, um besser abstrahieren und Programmier-Paradigmen umsetzen zu können, ein geeignetes Framework gesucht. Hierfür wurden zahlreiche Frameworks mit der Unterstützung von Dependency Injection (DI) und Aspect-Oriented Programming (AOP) untersucht. Aufgrund der Auswahl der Programmiersprache Java für die Umsetzung der Anwendung schränkte sich die Anzahl der Frameworks ein. Die Recherche ergab folgende vier Frameworks:

Frameworks	Sprache	Eigenschaft
PicoContainer	Java	DI, AOP, schlank
HiveMid	Java	DI, AOP-ähnliches Feature, IoC Container
Google Guice	Java	DI, AOP, IoC Container, Annotations, Generics, modular
Spring	Java	DI, AOP, IoC Container, Annotations, Generics, modular

Tabelle 4.1: DI-Frameworks

HiveMind und Guice bieten leichter verständliche Programmierungstechniken sowie einen prägnanteren und lesbaren Code gegenüber Spring. HiveMind fokussiert sich auf das Verbinden von Services. Seine Konfiguration erfolgt über eine XML-Datei oder eine eigene Definitions-Sprache. Hierdurch ist HiveMind ein kleiner und simpel gestalteter DI-Container. Guice hingegen unterstützt die neuen Features, wie Annotations und Generics die ab Java 1.5 zur Verfügung stehen. Dies hilft dabei, eine weitgehend aufgeräumte und einfache Konfiguration zu ermöglichen. HiveMind bietet zusätzlich die Möglichkeit, mit AOP zu arbeiten. Guice und Spring bieten sehr ähnliche Ansätze und kommen mit vielen Anforderungen, die Unternehmenssoftware erfüllen müssen, zurecht. Spring‘s Modularität bietet dabei einen größeren Vorteil. Die Module können in Spring, je nachdem welche Module der Entwickler benötigt, ohne viel Aufwand hinzugefügt werden. Guice ist durch

die geringere Komplexität zwar leichter zu verstehen und insgesamt kleiner als Spring. Dieser Punkt kann aber vernachlässigt werden, da durch die Modularität von Spring das Framework nach den Voraussetzungen des Entwicklers zusammengestellt werden kann. Schlussendlich wurde sich für das Spring-Framework entschieden, da die Flexibilität und Modularität von Spring die Entwicklung von Anwendungen stark vereinfacht und daher die beste Wahl darstellt.

4.2 Auswahl einer Datenbank

Als nächstes wurde für die spätere Speicherung der Interaktion zwischen Backend, Suchergebnissen und User, also das User-Feedback eine geeignetes eingebettetes Datenbanksystem gesucht. Die Recherche ergab folgende Datenbanken:

Datenbank	Sprache	Eigenschaft
SQLite	C	SQL-92-Standard, Transaktionen, Unterabfragen (Subselects), Sichten (Views), Trigger und benutzerdefinierte Funktionen, direkte Integrierung in Anwendungen, In-Memory-DB
H2	Java	Schnell, Referenzielle Integrität, Transaktionen, Clustering, Datenkompression, Verschlüsselung und SSL ,kann direkt in Java-Anwendungen eingebettet oder als Server betrieben werden, Direkte Unterstützung in Spring, In-Memory-DB
Apache Cassandra	Java	Spaltenorientierte NoSQL-Datenbank, Für sehr große strukturierte Datenbanken, Hohe Skalierbarkeit und Ausfallsicherheit bei großen, verteilten Systemen

Tabelle 4.2: Datenbanken

SQLite bietet einen leiten einstieg in die SQL-Welt. Dabei bietet es den größten Teil des SQL-92-Standards und kann Transaktionen, Unterabfragen und viele weitere Funktionen. Außerdem ist es eine In-Memory-DB. Leider unterstützt Spring Boot diese Datenbank nicht von Haus aus und es müssten Anpassungen in der Konfiguration vorgenommen werden. Apache Cassandra ist eine Spaltenorientierte NoSQL-Datenbank und ist für große strukturierte Daten, hohe Skalierbarkeit und Ausfallsicherheit ausgelegt. Da diese Datenbank für große Datenmengen ausgelegt ist, ist diese Datenbank für dieses Backend zu groß ausgelegt. H2 ist eine In-Memory-DB, welche schnell ist, Referenzielle Integrität,

Transaktionen, Clustering, Datenkompression unterstützt. Außerdem kann Spring Boot mit dieser Datenbank ohne besondere Maßnahmen verwendet und in diese Anwendung integriert werden. Daher wurde sich Schlussendlich für die H2 Datenbank entschieden.

4.3 Erstellung des Backends

Nach der Auswahl der Backendtechnologien wurde die Grundarchitektur des Backendes konzipiert und implementiert.

4.3.1 Kommunikation mit der Datenbank

Zunächst wurden Datenmodels, wie die `Query` oder`LoggingDocument` erstellt. Hieraus werden später die Tabellen der Datenbank generiert. Um mit der Datenbank kommunizieren zu können, gehört die Erstellung von DAOs dazu, welche die Kommunikationsschnittstelle bilden. Ein DAO generiert eine SQL Query und übermittelt diese an die Datenbank.

```
1 public interface LoggingDocDao extends JpaRepository<
    LoggingDocument, Long> {
2 LoggingDocument findByDocId(Long docId);
3 }
```

Beispiele hierfür sind die Speicherung und Abrufen von LoggingDocument Daten, welche ein Teil des User-Feedbacks darstellen. In dem zu betrachtenden Code Ausschnitt sieht man wie mit Hilfe von Spring die SQL Qyery findByDocId von einem LoggingDocument geniert wird. Dies findet über den Namen eines Interfaces statt. Die einzelnen Komponenten, welche implementiert wurden, kommunizieren nicht direkt über die DAOs mit der Datenbank, sondern dazwischen befindet sich noch ein Abstrahiertes Service Interface. Dadurch ist eine lose Kopplung zwischen den Komponenten, DAO und Datenbank möglich. Dies dient dazu, dass die Datenbank ohne große Änderungen in den Implementierungen austauschbar ist. Es ist dadurch nur notwendig, in den Konfigurationen und eventuell in den DAOs Änderungen vorzunehmen. Ein Beispiel für einen Service ist der `UserLoggingService`.

```
1 public class LoggingDocServiceImpl implements
    LoggingDocService {
```

```
2   public LoggingDocument findbyId(Long id) {
3   return loggingDocDao.findOne(id);
4   }}
```

In der Implantation des Interfaces wird nun das DAO aufgerufen. Wie hier im Beispiel zu sehen die Methode `findbyId`.

4.3.2 Controller

Die nächste Schritt ist es sogenannte Controller zu erstellen. Diese bilden eine wichtige Schnittstelle für die Kommunikation mit dem Frontend und Backend. Controller reagieren auf HTTP-Requests, welche von dem Frontend oder anderen Clients gesendet werden. Die Aufgabe ist es für die bestimmten Ressource-URLs bestimmte Ereignisse auszuführen. Ein Beispiel hierfür ist die Suchanfrage der Search Zeile im Frontend auszuwerten und die Suchergebnisse zurück zu senden.

```
1  @RequestMapping(method = RequestMethod.GET, path = "/")
2  public ModelAndView searchPage(
3  @RequestParam(defaultValue = "")
4  String query) {
5  ModelAndView modelAndView = new ModelAndView("search");
6  ...
7  List<ScoreDoc> list = querySearcher.search(query);
8  ...
9  modelAndView.addObject("searchResultPage", searchResultPage);
10 return modelAndView;}
```

In diesem Code Beispielabschnitt sieht man, dass wenn ein Request bei der Path-URL „/“ ausgelöst wird, wird die Funktion SearchPage aufgerufen und eine Suche ausgeführt. Hierfür wird der Request Parameter query ausgewertet. Die Suche wird mithilfe der Komponente Lucene durchgeführt, welches in Abschnitt 3 näher erläutert wird und anschließend die Suchergebnisse in einem modelAndView Objekt dem Frontend übergeben.

4.3.3 Frontendkomponenten

Im nächsten Schritt wurden die Komponenten, welche für das Frontend benötigt werden konzipiert und im Anschluss implementiert.

Nach dem die Suche durchgeführt wurde und die Lucene Komponente die Suchergebnisse zurückgegeben hat, wird die gesamte Ergebnisliste gesplittet. Hierbei wird für die angeforderte Seite eine Subliste erstellt, in welcher nur die erforderten Suchergebnisse enthalten sind und die restlichen Ergebnisse werden verworfen. Hierdurch ist es nicht erforderlich alle Ergebnisse zu transformieren, wodurch die Anwendung wesentlich schneller arbeitet.

Als nächstes wurde ein data transfer object (DTO) erstellt, um die relevanten Suchergebnisse, die in der Subliste enthalten sind, in das gewünschte Ausgabeformat überführt und in einer separaten Liste gesammelt. Das DTO hat dabei unter anderem die Variablen Autor, Titel, Snippet oder der Redirect Link, welcher auf die zugehörige PDF zeigt. Der Link hierfür wird in einer separaten Methode `createLink` erzeugt. zu diesem Zweck werden aus der docId, Query und dem Host ein Link erstellt. Zum Beispiel wird der folgende Link generiert: *http://localhost:8080/pdf/?docId=1&query=xyz*. Der Parameter `docId` ist dabei eine Id, welche die PDF zu dem Suchergebnis angibt und der Parameter `query` dient für das User-Feedback. Bei dem späteren klicken auf das Suchergebnis, wird in der Datenbank das Dokument, welches mit dem einer bestimmten Query gefunden wurde gespeichert. Damit ist es möglich Rückschlüsse auf die Wichtigkeit des Dokuments zu erkennen. Der eben beschrieben Vorgang wird in der Methode `mapDocumentListToSearchResults` vorgenommen. Nach dem die Liste der transformierten Suchergebnisse erstellt wurde, wird diese zu dem `searchResultPage` Objekt hinzugefügt und das Objekt mit weiteren Angaben ergänzt, welche im folgenden Code Abschnitt Ausschnittsweise zu erkennen ist.

```
1 List<ScoreDoc> split = pager.split(list, currentPage);
2 searchResultList = querySearcher.
    mapDocumentListToSearchResults(split,query);
3 searchResultPage.setTotalResults(list.size());
4 searchResultPage.setResultsOnPage(searchResultList);
5 searchResultPage.setPage(currentPage);
```

Dabei werden noch zum Beispiel die gesamt Anzahl an Suchergebnissen oder auf welcher Page man sich befindet gesetzt.

Die `searchResultPage` wird nun der Spring Thymeleaf Komponente übergeben und die `search.html` Page erstellt. Hierfür wurde ein `search.html` Template erstellt, in welchem Anweisungen stehen, wie mit den übergebenden Daten umgegangen werden soll. Thymeleaf befolgt dabei diese Anweisungen und wandelt diese in entsprechende HTML Komponenten um, damit im Anschluss nach der Umwandlung ein Webbrowser die Page anzeigen kann. Ein Beispiel der Anweisungen für Thymeleaf werden im folgenden Codeabschnitt aufgezeigt.

```
<div th:each="result : ${searchResultPage.resultsOnPage}">
  <h3 class="card-title">
    <a th:href="${result.webUrl.href}"
      th:text="${result.title}">
    </a>
  </h3>
</div>
```

In dem Codeabschnitt wird das `searchResultPage`-Objekt aufgerufen und in einer Schleife jedes DTO-Objekt mit Titel und der webURL in ein HTML h3-Tag, welches ein Link darstellt erstellt. Durch die Schleife wird also für jedes Element ein eigenes HTM-Element generiert. Nach der Erstellung der `search.html` Page wird die fertige Page über den Request zurückgegeben und der Webbrowser zeigt die Page an.

5 Evaluation und Fazit